Data Mining 팀 프로젝트

1. 프로젝트 목표 및 평가

실제 데이터를 활용하여 data-mining application 을 구현함. 데이터를 어떻게 획득하고 준비했는지 설명하고, 수업에서 배운 **서로 다른 주요 data-mining algorithms 를 최소 3 개** 적용한 후, 타당한 experimental protocol 에 따라 결과를 평가함. 성공적인 결과뿐 아니라 기대에 미치지 못한 결과도 정직하게 설명함.

평가 항목	반영 비율	제출 기한	제출 형식	평가 방법
보고서	22%	12 월 5 일 23:55 KST	Ajou Blackboard 에 *Team#_Report.pdf* 제출	담당 교수가 code 를 포함한 보고서 rubric 으로 평가함
GitHub code	보고서 평가에 포함	12 월 5 일 23:55 KST	Blackboard 에 repository URL 을 제출하고 보고서에도 기재함.	GitHub 제출 필수
발표	6%	12 월 5 일 23:55 KST	*Team#_Presentation.mp4*; 최대 30 MB; 지정된 Google Drive 폴더에 제출	동료 평가 후 담당 교수 검토·조정
동료 평가	2%	12 월 24 일 23:55 KST	배정된 발표 7–10 개 평가; 지정된 Google Form 사용	배정된 평가의 완료 여부 및 피드백의 질
합계	30%			

최종 성적 반영 점수 = 22 × (보고서 점수 / 100) + 6 × (발표 점수 / 100) + 2 × (동료 평가 참여 점수 / 100).

필수 제출물

- **팀별 최종 보고서 PDF 1 개**를 제출함. GitHub repository URL 과 제출 버전의 정확한 commit hash 를 포함함.
- **팀별로 접근 가능한 GitHub repository 1 개**를 제출함. 보고된 실험을 재현하는 데 필요한 code 와 관련 자료를 포함함.
- **팀별 발표 영상 1 개를 제출함. 길이는 최대 5 분임.**
- 각자 배정된 팀 발표 7–10 개에 대한 동료 평가를 제출함.

핵심 기술 요구사항

- 문제, 연구 동기, 목표, 범위를 명확히 제시함.
- 데이터 출처, 원저작자 또는 제공자, 획득 절차, dataset version 또는 접근일, 형식, 크기, 변수, preprocessing 을 문서화함. 모든 dataset 의 출처를 인용함.
- **수업에서 배운 서로 다른 주요 data-mining algorithms 를 최소 3 개 사용함(각 algorithm 은 수업 슬라이드 최소 5 장에서 다룬 내용이어야 함). Algorithm 이름을 명시하고 각각의 역할을 설명함. 서로 다른 hyperparameter settings, 동일 algorithm 의 다른 library implementation, 또는 다른 random seeds 는 서로 다른 algorithms 로 인정하지 않음. Transformations, feature engineering, sampling 에 해당하는 algorithms 는 합쳐서 최대 1 개까지만 인정함. Cleaning, missing values 처리 등 기타 preprocessing algorithms 는 개수에 포함하지 않음.**
- 전체 pipeline, 각 method, parameter 설정 및 선택 방법, baseline, evaluation metrics, 과제에 적합한 experimental protocol 을 설명함.
- 공정한 비교, 정량적 결과, 관련 시각화, 비판적 분석, 한계점을 제시함.
- **지정된 보고서 구조를 따르고**, 모든 출처를 명확하게 표시하며, AI 의 도움을 받았다면 사용 내역을 공개함.

담당 교수가 대안을 사전에 승인하지 않은 한 **3 개 algorithm 사용 요건은 필수**임. 단순한 기준 규칙은 baseline 으로 사용할 수 있지만, 수업에서 배운 주요 algorithm 으로는 인정하지 않음.

2. 제출 안내

보고서 및 발표 형식

- **보고서: 8–10 페이지, 글자 크기 10-point, 줄 간격 1.5** 로 작성함. 영문은 Times New Roman 을 사용하고, 한글은 가독성 있는 한글 지원 글꼴을 일관되게 사용함. 보고서는 한국어, 영어 또는 두 언어를 혼용하여 작성할 수 있음.
- 발표: **최대 5 분**이며, 처음 5 분까지만 평가함. 문제, 데이터, methods, evaluation, 주요 결과, 한계점을 설명함.
- **발표 언어**는 기존 분반 기준을 따름. 수요일/금요일 분반은 영어, 화요일/금요일 분반은 한국어로 발표함. 현재 분반의 안내를 확인함.
- 명확한 labels, 읽기 쉬운 표와 그림, IEEE-style 번호형 인용을 사용함.

GitHub repository 필수 구성

- README.md: 프로젝트 제목, 팀원, 문제 요약, repository 구조, 데이터 접근 방법, environment setup, 주요 결과를 재현하기 위한 정확한 commands 또는 notebook 실행 순서를 포함함.
- Source code 또는 notebooks: 해당하는 경우 data acquisition, preprocessing, 필수 algorithms 3 개 모두의 구현 또는 적용, evaluation, 결과 생성을 포함함. 팀이 작성한 code 와 외부 code 를 명확히 구분함.

3. 필수 보고서 구조

구성 항목	필수 내용
제목 및 팀 정보	간결한 제목, 팀 번호, 이름, 학번, GitHub URL, 제출 버전의 전체 commit hash 를 기재함.
Abstract	독립적으로 이해할 수 있는 1–2 개 문단으로 문제, 데이터, methods, 주요 정량적 발견 및 결과를 요약함. 그림과 인용은 포함하지 않음.
1. Introduction	문제, 연구 동기, 목표, 범위, 관련 선행연구를 인용과 함께 제시함.
2. Data acquisition and preprocessing	데이터의 원출처를 명시하고 인용함. Download, API, crawling, 직접 수집 등 팀이 데이터를 획득한 절차를 설명함. URL, version/접근일, sample size, attributes, 해당하는 경우 labels, 관련 descriptive statistics 를 제시함. Cleaning, missing values 처리, transformations, feature engineering, sampling 및 중요한 데이터 한계를 설명함.
3. Methods	전체 pipeline 과 수업에서 배운 서로 다른 주요 algorithms 최소 3 개를 설명함. 각 algorithm 의 목적, 관련 mechanism, 구현, 가정, 설정 및 선택 근거를 제시함. 외부 libraries 와 수정·활용한 code 를 명시함. Algorithm 이름만 나열하는 것은 충분하지 않음.
4. Experimental design and evaluation	Baseline, metrics, 비교 protocol 을 정의함. Data split/validation 또는 과제에 적합한 다른 평가 절차, parameter selection, 해당하는 경우 leakage 방지, computational environment 를 설명함. 해당하는 경우 test data 를 model selection 과 분리함.
5. Results and discussion	해석 가능한 표와 그림을 사용하여 필수 algorithms 모두의 결과를 제시하고 비교함. 결과를 프로젝트 목표와 연결하며, 해석 없이 점수만 나열하지 않음.
6. Conclusion and limitations	프로젝트 질문에 답하고, 근거가 뒷받침하는 결과를 요약하며, 한계와 기대에 미치지 못한 결과를 인정하고, 현실적인 후속 과제를 제시함.
References	Datasets, methods, 논문, software, 재사용한 code 및 기타 외부 자료에 대해 본문 인용과 일치하는 IEEE-style 번호형 References 를 작성함.
AI-use disclosure	AI tool/제공자, 확인 가능한 model 또는 version, 대략적인 사용 시기, 도움받은 작업, 영향을 받은 sections/files, 결과를 검증하거나 수정한 방법을 명시함. Generative AI 를 사용하지 않았다면 이를 명시함.
Github	GitHub URL 을 기재함. Private repository 로 유지하려면 “leesael” 또는 sael@ajou.ac.kr 을 collaborators 에 추가함.

모든 필수 요소에 명확한 제목을 붙이고 쉽게 찾을 수 있다면 동등한 subsection 구성도 허용됨. 제목만 있는 것으로는 내용 요건을 충족하지 못함.

4. 발표 동료 평가 rubric

발표의 **처음 5 분** 안에 제시된 근거만 평가함. 자신감, 억양, 시각적 완성도, 주제의 복잡성을 근거로 구현의 질, 보이지 않는 노력, 팀워크를 추정하지 않음. 각 항목을 독립적으로 평가함.

평가 항목	배점	만점 기준

평가 항목	배점	만점 기준
문제, 데이터 및 연구 동기	20	문제와 목표가 명확함. Dataset, 출처, 관련 특성, 주요 준비 과정을 설명함. 청중이 과제의 중요성을 이해할 수 있음.
Methods 및 기술적 적절성	25	Data-mining pipeline 과 필수 algorithms 3 개의 역할을 이해할 수 있음. Method 선택이 과제에 적합하고 설명이 기술적으로 정확함.
결과, evaluation 및 결론	25	의미 있는 결과, 적절한 metrics, baseline 또는 공정한 비교를 제시함. 결론이 근거에 기반하며, 한계 또는 기대에 미치지 못한 결과를 인정함.
구성 및 전달력	20	문제-method-결과-결론으로 이어지는 일관된 구조를 갖춤. 슬라이드와 그림이 읽기 쉽고, 용어가 명확하며, 설명을 이해할 수 있고, 핵심 내용이 5 분 안에 포함됨.
실질적인 탐구	10	단순한 library 시연을 넘어서는 작업을 보여줌. 예를 들어, 근거 있는 preprocessing, 초점을 맞춘 비교, error analysis, sensitivity analysis 또는 data-mining 과제에 대한 논리적인 탐구를 제시함.
합계	100	모든 평가 항목에 아래의 rating scale 을 적용함.

5. 최종 보고서 평가 rubric

보고서는 제출된 GitHub 버전과 함께 평가함. 각 항목은 필수 자료의 존재 여부뿐 아니라 기술적 정확성, 완성도, code 및 결과와의 일관성을 평가함.

평가 항목	배점	만점 기준
문제 및 목표	5	Data-mining 과제, 연구 동기, 구체적인 목표, 관련 맥락을 명확히 정의함.
필수 구조 및 내용	5	지정된 보고서 구조를 따름. 모든 필수 sections 가 존재하며, 제목이 명시되고 실질적인 내용을 포함함. 제출 식별 정보와 팀 정보가 완전함.
데이터 설명, 획득 및 준비	15	데이터 원출처를 명시하고 인용함. 획득 방법을 정확히 설명하고, version/접근일, 크기, 형식, variables/labels, 관련 통계 및 시각화, preprocessing, 중요한 데이터 한계나 제한사항을 문서화함.
수업에서 배운 algorithms 3 개 이상	15	수업에서 배운 서로 다른 주요 data-mining algorithms 를 최소 3 개 사용함(또는 승인된 대안을 적용함). 각 algorithm 의 역할과 관련성을 설명함.
기술적 method 설명	15	구현을 이해할 수 있도록 end-to-end pipeline 과 각 algorithm 을 충분히 설명함. 가정, parameters, feature processing, libraries, 설계 선택을 정확하게 문서화하고 code 와 일치시킴.
실험 설계 및 evaluation	10	적절한 metrics 와 baseline 을 정의하고, parameter selection 과 과제에 적합한 validation 을 설명함. 공정한 비교를 수행하고 일관된 protocol 을 사용함.
결과 및 기술적 분석	10	필수 algorithms 각각의 정량적 결과, 명확한 labels 가 있는 표와 그림, 의미 있는 비교를 제시함. 패턴, 오류, trade-offs, 한계를 해석하며 주장이 제시된 근거와 일치함.
GitHub 제출	10	제출된 commit 의 repository 에 접근할 수 있음. Code 는 데이터 준비, 모든 필수 algorithms, evaluation, 주요 결과 생성을 포함함. README, environment specification, 데이터 접근 안내, settings/seeds, 실행 절차를 제공함.
인용, 출처 표시 및 AI 사용 공개	10	정확한 본문 인용과 이에 대응하는 IEEE-style References 를 사용함. 원본 데이터, methods, 논문, software, 재사용 code, 외부 자료의 출처를 표시함. 보고서와 repository 에서 AI 사용 내역을 구체적이고 일관되게 공개하거나 미사용을 명시함. AI 가 도운 주장을 검증하고, AI 출력을 권위 있는 근거로 취급하는 대신 원출처를 인용함.
결론, 한계 및 기여	5	과장 없이 목표에 답하는 결론을 제시함. 한계와 후속 과제가 구체적이며 팀원별 기여가 명확함.
합계	100	보고서 점수는 전체 성적의 22%에 반영됨.

필수 요건 확인: 서로 다른 수업 algorithms 3 개, 실질적인 데이터 획득 설명, method 설명, evaluation protocol 및 결과, 필수 보고서 sections, 접근 가능한 GitHub commit, 출처 인용 및 AI 사용 내역. 누락된 요건은 해당 rubric 항목에 반영하며, 다른 항목의 강점으로 가려지지 않도록 함.

6. 평가 지침 및 출처 표시

공통 performance scale

평가 등급	배율	기준
Excellent	1.00	필수 근거가 완전하고, 기술적으로 정확하며, 구체적이고 충분히 뒷받침됨.
Good	0.80	대부분의 요건을 충족하며, 경미한 누락이 작업의 타당성을 훼손하지 않음.
Developing	0.60	일부 요건을 충족하지만 중요한 누락이나 오류가 남아 있음.
Insufficient	0.40	제시된 근거가 제한적이며, 중대한 누락이나 오류로 해당 항목의 완성도가 낮음.
Missing / not demonstrated	0.00	필수 근거가 없거나 평가할 수 없음.

항목 점수 = 항목별 최대 배점 × 평가 등급 배율. 항목별 점수를 합산하여 100 점 만점으로 산출함.

데이터, software 및 AI 출처 표시 요건

- Datasets: 원저작자/제공자와 dataset 제목, 확인 가능한 연도 또는 version, DOI 또는 URL, 필요한 경우 접근일을 인용함. Data section 에서 획득 과정을 설명함. Reference 만 제시하는 것으로는 데이터를 획득하고 처리한 방법이 설명되지 않음.
- Methods 및 software: 관련 원논문 또는 공식 documentation 을 인용하고, 재현성에 영향을 주는 경우 software version 을 명시함. 수정·활용한 code 의 출처를 보고서와 repository 에 표시하고, 해당하는 경우 원본 링크와 license 를 포함함.
- AI assistance: tool/제공자, 확인 가능한 model/version, 사용 날짜 또는 기간, 목적, 영향을 받은 보고서 sections 또는 code files 를 공개함. 출력을 검증하고 수정한 방법을 설명함. Model 식별 정보를 확인할 수 없다면 임의로 만들어 기재하지 않음.
- AI 가 생성한 사실 주장, references, 데이터 설명, code 는 반드시 확인함. 사실 및 방법론적 주장에는 근거가 되는 원출처를 인용함. 사용 내역을 공개하더라도 기존 수업 정책을 위반하는 AI 사용이 허용되는 것은 아님.
- 허가 없이 기밀 정보, 제한된 데이터 또는 개인정보를 AI tools 에 입력하지 않음. AI 가 생성한 데이터나 synthetic data 를 직접 수집한 관측값처럼 설명하지 않음.

AI-use disclosure 작성 예시

"본 팀은 [기간] 동안 [작업]을 위해 [tool/제공자; 확인 가능한 model/version]을 사용함. 도움받은 부분은 [보고서 sections 및/또는 code files]임. [출처 확인, tests 또는 수동 검토]를 통해 출력을 검증하고 [구체적인 부분]을 수정함. 제출한 작업에 대한 책임은 본 팀에 있음."

Generative AI 를 사용하지 않은 경우: "보고서, code, 그림 또는 발표를 준비하는 과정에서 generative AI tools 를 사용하지 않음."

Github README 구성 예시

Overview • Team • Repository layout • Environment/setup • Data sources and acquisition • Preprocessing • Algorithms • Experiment commands/configurations • Evaluation • Reproducing tables/figures • References and external code • AI-use statement

6. 정책 및 최종 제출 checklist

기존 정책 유지: 보고서 또는 발표 중 하나라도 제출하지 않으면 C 미만의 성적을 받게 됨. 이것이 전체 교과목 성적을 의미하는지는 담당 교수의 확인이 필요함. GitHub 는 보고서 rubric 에서 평가하는 필수 보조 제출물이며, code 미제출에 따른 별도의 추가 성적 상한은 이 문서에서 도입하지 않음.

기존 지각 제출 정책: 보고서/발표는 지각 1 일당 10% 감점하며, 최종 마감은 12 월 8 일 23:55 임. 이후에는 해당 항목을 0 점 처리함. 감점이 percentage points 인지 취득 점수의 일정 비율인지, 하루 미만의 지각을 어떻게 계산하는지, GitHub code 에 어떻게 적용하는지는 담당 교수가 명확히 안내해야 함.

- 보고서 PDF 에 모든 필수 sections, 수업 algorithms 3 개 이상, 데이터 획득, methods, evaluation, 결과, 인용, 기여 내역, AI 사용 공개가 포함됨.
- GitHub repository 에 접근할 수 있고 필수 자료가 포함되어 있으며, Blackboard 및 보고서의 URL/commit hash 와 일치함.
- 발표 영상은 최대 5 분, 최대 30 MB 이며 정상적으로 재생됨.
- 공지된 마감일까지 개인별 동료 평가를 완료함.