Data Mining 프로젝트 주제 아이디어

요구사항	주제 선택 시 적용 기준
수업에서 배운 algorithms 3 개 이상	수업에서 배운 서로 다른 주요 data-mining algorithms 를 최소 3 개 구현하거나 적용함. 인정되는 각 algorithm 은 수업 슬라이드 최소 5 장에서 다룬 내용이어야 함. 해당 강의 자료를 명시하고 각 algorithm 의 역할을 설명함.
별도 algorithm 으로 인정되지 않는 경우	동일 algorithm 의 서로 다른 hyperparameters, random seeds 또는 library implementations 는 별도로 인정하지 않음. Transformations, feature engineering 또는 sampling 에 해당하는 algorithm 은 합쳐서 최대 1 개까지만 인정함. Cleaning 및 missing-value handling 은 인정하지 않음.
Link Analysis 수업 범위	담당 교수가 확인한 수업 주제는 PageRank, Personalized PageRank, TrustRank, Random Walk with Restart 임. 인정 요건을 충족하는 수업 methods 를 최소 3 개 선택함. 수업에서 배운 formulation 을 설명하며, 선택한 구현이 동등하다면 이름만을 근거로 실질적인 차이를 주장하지 말고 그 동등성을 보고함.
기타 algorithm 제안	Link Analysis 외 영역에서 제시한 algorithm 예시는 조건부 제안이며, 수업에서 다루었음을 확인한 것은 아님. 인정 요건을 충족하지 않는 예시는 적격 수업 algorithms 로 대체하거나 프로젝트 시작 전에 대안에 대한 승인을 받음.
Baseline 및 평가	적절한 baseline 을 포함함. 단순한 규칙이 자동으로 주요 algorithm 으로 인정되는 것은 아님. 동일 과제를 수행하는 methods 는 일관된 protocol 로 비교하고, 서로 다른 과제를 수행하는 pipeline 구성요소는 개별적으로 평가하여 기여를 정당화함.
데이터 및 출처 표시	출처, 획득 방법, version/접근일, 선택한 subset, preprocessing, license 및 한계를 문서화함. 공개되어 있다는 것이 재배포 허가를 의미하지는 않음. 데이터, methods, software 및 외부 code 를 인용하고, AI 의 도움을 받았다면 사용 내역을 공개하며 미사용 시 이를 명시함.

1. Recommender Systems

프로젝트 주제	공개 datasets (클릭 가능)	Algorithm 구성	목표 및 수행 범위	평가 및 유의사항
A. Movie Recommendation	MovieLens HetRec 2011 MovieLens	구성 예시: collaborative filtering/content-based/latent feature + clustering + Apriori 임. 명확히 정의한 grouping 과제에 clustering 을 사용하고, 문서화한 training-only positive-rating baskets 에 Apriori 를 적용함.	추천 품질을 비교하고 cold start 를 탐구함. User/movie groups 또는 association rules 가 추천에 어떤 영향을 주는지 설명하고, grouping 을 별도로 평가함. MovieLens 100K 또는 소규모 release 로 시작함.	Rating prediction 에는 MAE/RMSE 를, ranking 에는 Precision@K, Recall@K, NDCG@K 를 사용함. Popularity baseline 및 동일한 held-out protocol 을 적용함. Unseen-user/item tests 는 일반적인 splits 와 구분함.
B. Music Recommendation	HetRec 2011 Last.fm Million Song Dataset Taste Profile / complementary data	구성 예시: collaborative filtering/content-based/latent feature + clustering 임. Listening baskets 와 명확한 grouping 목표를 정의함. 또는 인정 요건을 충족하는 다른 수업 algorithms 3 개를 선택함.	Last.fm 을 이용한 artist-level recommendation 을 선택하거나, song features 와 Taste Profile interactions 를 정렬하여 song-level 과제를 수행함. Sparse histories 또는 popularity bias 를 탐구함. 기본 Million Song Dataset 은 derived features 를 제공하며, 음원이나 explicit ratings 를 제공하는 것은 아님.	Recall@K, NDCG@K, coverage, diversity 및 청취 이력 길이별 결과를 평가함. Popularity baseline 을 사용함. Grouping 및 rule-based 구성요소의 기여를 평가하고, interactions 와 metadata 의 정렬 방법을 문서화함.
C. Product Recommendation	Amazon Reviews 2023 UCI Online Retail	구성 예시: collaborative filtering/content-based/latent feature + Apriori + clustering 임. Interaction/basket 구성 방법을 정의하고 각 구성요소의 역할을 설명함. 여러 preprocessing 단계를 추가 algorithms 로 계산하지 않음.	Review interactions 또는 구매 이력으로 상품을 추천함. 인기가 낮은 상품을 분석하고, 사용 가능한 attributes 를 반영함. 하나의 category/subset 을 사용함. Reviews 는 완전한 구매 기록이 아니며, demographics 가 존재한다고 가정하지 않음.	Recall@K, NDCG@K, catalog coverage 및 popularity group 별 성능을 평가함. Popularity/item-co-occurrence baselines 와 비교함. 일관된 candidates 와 splits 를 사용하고, clustering 구성요소를 별도로 평가함.

2. Link Analysis

PageRank (PR), Personalized PageRank (PPR), TrustRank (TR), Random Walk with Restart (RWR)

프로젝트 주제	공개 datasets (클릭 가능)	Algorithm 구성	목표 및 수행 범위	평가 및 유의사항
A. Global vs. Seed-Based Ranking	SNAP: web-Stanford / web-Google / cit-HepTh	PR + PPR + RWR 을 적용함. Global rankings 와 seed-based rankings 를 비교함. 동일한 graph 와 일관된 convergence criteria 를 사용함.	수업 formulation 을 구현하고 seed 선택, damping/restart 설정, dangling nodes 및 convergence 를 탐구함. Degree ranking 을 baseline 으로 사용함. Parameter 변경은 sensitivity studies 이며 추가 algorithms 가 아님.	Runtime, memory, iterations, rank correlation, top-K overlap 및 robustness 를 평가함. 외부 평가 목표가 정의된 경우에만 relevance accuracy 를 주장함. PPR/RWR 이 일치한다면 그 동등성을 문서화하고 설명함.
B. Topic-Specific Ranking	Cora (LINQS)	PR + PPR + RWR 을 적용하며, personalized methods 에는 주제에 따라 선택한 seed papers 를 사용함.	Global prominence 와 topic-focused retrieval 을 비교함. Seed 크기/품질 및 restart 설정을 분석함. Seed 구성 방법을 설명하고, test-time tuning 에 evaluation labels 를 사용하지 않음.	Held-out topic relevance 를 기준으로 Precision@K 또는 NDCG@K 를 평가하고, runtime 및 stability 를 측정함. Seeds 와 tuning labels 를 held-out evaluation labels 와 분리하고, transductive graph 접근 여부를 공개함.
C. Trust-Aware Spam Ranking	WEBSPAM-UK2007	PR + PPR + TR 을 적용함. 타당한 출처가 있는 경우 PPR 에는 topic/interest seeds 를 사용하고, TR 에는 신뢰할 수 있는 nonspam seeds 를 사용함. Seed 의 의미와 구성 방법을 문서화함.	Global ranking 과 서로 다른 seeded rankings 를 비교함. Trusted-seed 의 품질과 개수를 분석함. Host graph/subgraph 를 사용하며, trusted seeds 는 training information 에서 선택해야 함. Topic seed set 에는 근거 있는 metadata 또는 문서화된 proxy 가 필요함.	PR-AUC, ROC-AUC 및 최고 위험 hosts 에 대한 precision 을 평가함. 각 ranking 을 risk score 로 변환하는 방법과 점수 방향을 명시함. Seed 선택/tuning 과 test labels 를 분리함.
D. Structural Prominence in Social Networks	SNAP: ego-Twitter / wiki-Vote	PR + PPR + RWR 을 적용함. 명확히 정의한 관심사 또는 시작 communities 를 나타내는 seed groups 를 선택함. Degree ranking 을 baseline 으로 사용함.	Global prominence 와 seed-relative prominence 를 비교함. Edge direction, seed 선택 및 edge removal 에 대한 robustness 를 탐구함. 독립적인 근거가 없는 한 실제 영향력으로 단정하지 않고 “structural prominence”로 표현함.	Rank correlation, top-K overlap, stability, runtime 및 memory 를 평가함. Seeds 및 graph perturbations 에 대한 의존성을 보고함. Ranking 의 불일치만으로 특정 method 가 더 우수하다고 판단하지 않음.
E. Personalized Paper Recommendation	Cora (LINQS) SNAP: cit-HepTh	PR + PPR + RWR 을 적용함. PR 을 global reference 로 사용하고 seed papers 로 가상 관심사를 표현함. Personalized formulations 간 동등성이 있다면 이를 설명함.	관련 논문을 추천하고 global outputs 와 personalized outputs 를 비교함. Citation-count 또는 text-similarity baseline 을 사용함. Seed sampling 과 각 method 에서 접근 가능한 graph/features 를 문서화함.	정의된 held-out citation 또는 topic-relevance 과제에서 Recall@K/NDCG@K 를 평가하고, coverage 및 runtime 을 측정함. Seed 로 표현한 관심사는 가상으로 설정한 것이며, 측정된 사용자 만족도가 아님. Training/evaluation leakage 를 방지함.

3. Mining Social Networks and Community Detection

프로젝트 주제	공개 datasets (클릭 가능)	Algorithm 구성	목표 및 수행 범위	평가 및 유의사항
A. Social Communities	SNAP: ego-Facebook	Community-detection algorithms 3 개를 사용함. 조건부 예시는 label propagation, Louvain, spectral clustering 임.	탐지한 groups 와 제공된 social circles 를 비교함. Overlapping memberships 및 disjoint partitions 의 한계를 탐구함. Direction/weight 처리와 isolated nodes 처리 방법을 기록함.	Modularity, conductance, runtime 및 overlapping labels 에 적합한 reference-agreement measure 를 평가함. 동일한 graph 를 사용하고 outputs 와 circles 를 대응시키는 방법을 문서화함.
B. Product Communities	SNAP: com-Amazon	문서화한 하나의 product subgraph 에 서로 다른 적격 community-detection algorithms 3 개를 적용함.	함께 구매되는 상품 groups 를 찾고, category-derived communities 와 비교하며, groups 를 연결하는 상품을 분석함. Nodes 는 고객이 아니라 상품임. Customer graph 를 구성하는 것은 다른 과제임.	Modularity, conductance, runtime 및 category agreement 를 평가함. Overlapping categories 처리 방법을 설명하고 held-out reference labels 로 tuning 하지 않음. Method 별 설정과 output types 를 보고함.
C. Biological Functional Modules	STRING downloads	동일한 confidence-filtered protein graph 에 서로 다른 적격 community-detection algorithms 3 개를 적용함.	하나의 organism 또는 protein subset 을 사용함. Confidence thresholds 및 module stability 를 분석함. STRING 은 physical interactions 뿐 아니라 functional associations 도 포함함. Threshold 변경은 추가 algorithms 로 인정되지 않음.	Modularity, conductance, stability 및 runtime 을 평가함. 선택 사항인 functional enrichment 에는 별도로 인용한 annotations 와 명시적인 절차가 필요함. 구조적 품질만으로 biological validation 이 이루어지는 것은 아님.
D. Research Communities	Cora (LINQS) SNAP: ca-HepTh	서로 다른 적격 community-detection algorithms 3 개를 사용함. Citation graph 또는 coauthorship graph 를 선택하고 node/edge 의 의미를 정의함.	관련 논문 또는 연구자 groups 를 찾고 bridging nodes 를 분석함. Graph representations 를 비교한다면 고정한 조건을 설명함. Citation nodes 는 논문이며, coauthorship nodes 는 연구자임.	Modularity, conductance, runtime 및 labels 가 있는 경우 topic agreement 를 평가함. 호환되지 않는 node types 또는 reference labels 를 서로 대체 가능한 것처럼 비교하지 않음.
E. Algorithm Benchmark	SNAP: ego-Facebook, com-Amazon, ca-HepTh	적격 algorithms 를 최소 3 개 사용함. 수행 가능한 networks 를 선택하여 일관된 pipeline 을 적용함.	Graph 크기, random seeds, resolution settings 및 edge perturbations 를 탐구함. 관련 없는 algorithms 를 많이 실행하기보다 통제된 비교를 우선함. 모든 sampling 및 graph-construction 단계를 문서화함.	Network 별 runtime/memory, modularity, conductance, stability 및 적합한 reference 가 있는 경우 external agreement 를 평가함. 실험 조건과 variability 를 보고함. Parameter sweeps 는 추가 algorithms 가 아님.

4. Mining Data Streams

프로젝트 주제	공개 datasets (클릭 가능)	Algorithm 구성	목표 및 수행 범위	평가 및 유의사항
A. Previously Seen Item Detection	NASA HTTP logs UCI Online Retail	Bloom filter + Flajolet–Martin + reservoir sampling 등 적격인 세 번째 method 를 적용함. 모든 구성요소에 서로 연관된 stream-monitoring 역할을 부여함.	Membership 에 초점을 두되 distinct counts 를 모니터링하고 검토용 sample 도 유지함. URL 또는 customer–product keys 를 정의함. 반복되는 keys 가 반드시 잘못 중복된 records 를 의미하는 것은 아님.	Exact set 대비 membership false-positive rate, exact count 대비 distinct-count error, 세 번째 구성요소의 sampling behavior, 전체 memory 및 throughput 을 평가함. 인정되는 모든 methods 를 평가함.
B. Distinct-Count Estimation	NASA HTTP logs	Flajolet–Martin + Bloom filter + reservoir sampling 등 적격인 세 번째 method 를 적용함.	Distinct hosts/resources 에 초점을 두고 novelty monitoring 과 audit sample 을 추가함. Hash functions, repeated trials 및 aggregation 을 분석함. Hostnames/IP addresses 는 검증된 사용자 식별자가 아님.	Relative error, variability, memory, throughput, membership error 및 세 번째 구성요소 고유의 metric 을 평가함. Hash 개수 및 aggregation settings 는 추가 algorithms 가 아님.
C. Integrated Stream Dashboard	NASA HTTP logs UCI Online Retail	Bloom filter + Flajolet–Martin + reservoir sampling 등 적격인 세 번째 algorithm 을 적용함.	Membership, distinct counts 및 sample-based inspection 결과를 보고함. Cumulative processing 과 fixed-window processing 을 비교하고 resets/reconstruction 방법을 명시함. 원본 stream 을 각 structure 에 독립적으로 입력함.	구성요소별 errors 및 sample behavior, 통합 memory, throughput 및 window effects 를 평가함. Bloom-filter false positives 가 estimator 또는 sampler 로 전달되는 입력을 의도치 않게 제어하지 않도록 함.
D. Novelty Monitoring for Anomaly Detection	Numenta Anomaly Benchmark (NAB) NASA HTTP logs	Bloom filter 와 명확한 역할을 가진 다른 적격 수업 algorithms 2 개를 적용함. 한 가지 구성 예시는 monitoring/auditing 을 위한 Flajolet–Martin 과 적격 reservoir sampler 를 추가하는 것임.	Discrete patterns 및 training period 를 정의함. Anomaly scores 를 생성하는 구성요소와 monitoring 을 지원하는 구성요소를 구분함. 별도의 scoring/verification rule 과 component ablations 를 사용함.	Detection precision/recall/F1 및 delay, 구성요소별 error, memory 및 throughput 을 평가함. NAB labels 를 사용하거나 logs 에 대한 proxy/injection 과제를 문서화함. Unseen 이라는 이유만으로 malicious 하다고 판단하지 않음.